

✓ Ollama ✓
LM Studio

AVX

pytorch

torch

hugging face

1b → fp32 (4by)
fp16 (2by)
int8 (1by)
int4 (.5)
6,5

$$\frac{\text{token}}{\text{line}} \approx 75\%$$

z_i
 $(1, 5, 9, 4, 3, \dots, 1) \rightarrow \text{data max}$

$\downarrow$
 $\{1, 5, 9\}$ Score

$$P_i = \frac{e^{z_i}}{\sum_{i=1}^K e^{z_i}}$$

P_i
 $\left[\begin{array}{c} \cdot 9 \\ \cdot 2 \end{array} \right]$

$$\text{Softmax}(z_i, T) \rightarrow P_i = \frac{e^{z_i/T}}{\sum_{i=1} e^{z_i/T}}$$

برای افزایش مدل

$T \downarrow$ → توزیع انحراف شاربتر
 $T = 0$ → کامل و قطعی، یکی با یکی برابر

$T \uparrow$ ، توزیع → flatter → صافتر
 (پهن‌تر) →

top k



از k، رکش با محاکم به انتخاب

top-p



9


امکان
بسیار
از k، رکش بر روی 9.9

Tool Call

→ function Calling

Queen Instruct

RAG



$\vec{P}$

embed
prompt

$\vec{C}$

embed
chunk
vector DB

$$\text{CosA} = \frac{P \cdot C^T}{\|P\| \|C\|}$$